

第2章 数学基础

2.1 向量与矩阵

1. 向量 由线性代数知， n 个有序的数 x_1, x_2, \dots, x_n 组成的数组称 n 维向量。

n 维向量写成一行时称行向量，记作 X
写成一行时称行向量，记作 X^T

即

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad X^T = [x_1 \quad x_2 \quad \cdots \quad x_n]$$

2. 矩阵

$n \times m$ 个有序的数 a_{ij} ($i = 1, 2, \dots, m; j = 1, 2, \dots, n$),
排成的 m 行 n 列数表, 称 $m \times n$ 阶矩阵。
用大写字母 A 或 $A_{m \times n}$ 表示。

即

$$A = A_{m \times n} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

3. 矩阵的运算

向量和矩阵之间可以进行各种运算, 如
加法运算;
数乘运算外;
一般的乘法运算。

4.矩阵的乘法运算

令

$$X = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \quad C = \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix}, \quad A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

则有

●向量与向量相乘

$$C^T X = [c_1, c_2, \dots, c_n] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = c_1 x_1 + c_2 x_2 + \dots + c_n x_n \quad (\text{数})$$

$$CX^T = \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix} [x_1, x_2, \dots, x_n] = \begin{bmatrix} c_1 x_1 & c_1 x_2 & \cdots & c_1 x_n \\ c_2 x_1 & c_2 x_2 & \cdots & c_2 x_n \\ \vdots & \vdots & \ddots & \vdots \\ c_n x_1 & c_n x_2 & \cdots & c_n x_n \end{bmatrix} \quad (\text{矩阵})$$

● 向量与向量相乘

$$\begin{aligned} X^T A &= \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \\ &= [x_1 a_{11} + x_2 a_{21} + x_3 a_{31}, \quad x_1 a_{12} + x_2 a_{22} + x_3 a_{32}, \\ &\quad x_1 a_{13} + x_2 a_{23} + x_3 a_{33}] \quad (\text{行向量}) \end{aligned}$$

● 向量与矩阵相乘

$$AX = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix} = \begin{bmatrix} a_{11}c_1 + a_{12}c_2 + a_{13}c_3 \\ a_{21}c_1 + a_{22}c_2 + a_{23}c_3 \\ a_{31}c_1 + a_{32}c_2 + a_{33}c_3 \end{bmatrix} \quad (\text{列向量})$$

$$\begin{aligned}
 X^T A X &= \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \\
 &= (x_1 a_{11} + x_2 a_{21} + x_3 a_{31}) y_1 + (x_1 a_{12} + x_2 a_{22} + x_3 a_{32}) y_2 \\
 &\quad + (x_1 a_{13} + x_2 a_{23} + x_3 a_{33}) y_3 \quad (\text{数})
 \end{aligned}$$

即

$$\begin{bmatrix} \text{行} & \text{向} & \text{量} \end{bmatrix} \begin{bmatrix} \text{矩} & \text{阵} \end{bmatrix} = \begin{bmatrix} \text{行} & \text{向} & \text{量} \end{bmatrix}$$

$$\begin{bmatrix} \text{矩} & \text{阵} \end{bmatrix} \begin{bmatrix} \text{列} & \text{向} & \text{量} \end{bmatrix} = \begin{bmatrix} \text{列} & \text{向} & \text{量} \end{bmatrix}$$

$$\begin{bmatrix} \text{行} & \text{向} & \text{量} \end{bmatrix} \begin{bmatrix} \text{矩} & \text{阵} \end{bmatrix} \begin{bmatrix} \text{列} & \text{向} & \text{量} \end{bmatrix} = \text{数}$$

2.2 方向导数与梯度

(1) 导数是函数在某点的变化率的数学描述

$$\left. \frac{df}{dx} \right|_{x=x_k}$$

一元函数 $f(x)$ 在点 x_k 的一阶导数

$$\frac{\partial f(X^k)}{\partial x_1}, \frac{\partial f(X^k)}{\partial x_2}, \dots$$


多元函数 $f(X)$ 在点 X^k 的一阶偏导数

$$\frac{\partial f(X^k)}{\partial S}$$

多元函数 $f(X)$ 在点 X^k 沿任意方向 S 的一阶偏导数, 称方向导数

对于二元函数，如图所示
方向导数可根据定义写作

$$\begin{aligned}\frac{\partial f(X^k)}{\partial S} &= \lim_{\Delta S \rightarrow 0} \frac{f(X^k + \Delta S) - f(X^k)}{\Delta S} \\ &= \lim_{\Delta x_1 \rightarrow 0} \frac{f(x_1 + \Delta x_1, x_2) - f(x_1, x_2)}{\Delta x_1} \cdot \frac{\Delta x_1}{\Delta S} \\ &\quad + \lim_{\Delta x_2 \rightarrow 0} \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1 + \Delta x_1, x_2)}{\Delta x_2} \cdot \frac{\Delta x_2}{\Delta S}\end{aligned}$$



$$\begin{aligned}&= \frac{\partial f(X^k)}{\partial x_1} \cos \alpha_1 + \frac{\partial f(X^k)}{\partial x_2} \cos \alpha_2 \\ &= \left[\frac{\partial f(X^k)}{\partial x_1}, \frac{\partial f(X^k)}{\partial x_2} \right] \begin{bmatrix} \cos \alpha_1 \\ \cos \alpha_2 \end{bmatrix}\end{aligned}$$

同理，对于一般 n 元函数有

$$\frac{\partial f(X^k)}{\partial S} = \frac{\partial f(X^k)}{\partial x_1} \cos \alpha_1 + \frac{\partial f(X^k)}{\partial x_2} \cos \alpha_2 + \dots + \frac{\partial f(X^k)}{\partial x_n} \cos \alpha_n$$

$$= \left[\frac{\partial f(X^k)}{\partial x_1}, \frac{\partial f(X^k)}{\partial x_2}, \dots, \frac{\partial f(X^k)}{\partial x_n} \right] \begin{bmatrix} \cos \alpha_1 \\ \cos \alpha_2 \\ \dots \\ \cos \alpha_n \end{bmatrix}$$

$$= [\nabla f(X^k)]^T S^0$$

式中 $\nabla f(X^k)$ 称函数 $f(X)$ 在点 X^k 的梯度。


(2) 梯度是一个向量

$$\nabla f(\mathbf{X}^k) = \left[\frac{\partial f(\mathbf{X}^k)}{\partial x_1}, \frac{\partial f(\mathbf{X}^k)}{\partial x_2}, \dots, \frac{\partial f(\mathbf{X}^k)}{\partial x_n} \right]^T$$

方向导数与梯度的关系

$$\begin{aligned} \frac{\partial f(\mathbf{X}^k)}{\partial S} &= [\nabla f(\mathbf{X}^k)]^T \cdot \mathbf{S}^0 \\ &= \|\nabla f(\mathbf{X}^k)\| \cdot \|\mathbf{S}^0\| \cdot \cos \langle \nabla f(\mathbf{X}^k), \mathbf{S} \rangle \\ &= \|\nabla f(\mathbf{X}^k)\| \cdot \cos \langle \nabla f(\mathbf{X}^k), \mathbf{S} \rangle \end{aligned}$$


此式表明，函数在某点沿方向 \mathbf{S} 的
方向导数等于该点的梯度在方向 \mathbf{S}
上的投影。



(3) 梯度的方向

1) 当方向 S 与梯度垂直时


$$\frac{\partial f(X^k)}{\partial S} = [\nabla f(X^k)]^T \cdot S = 0$$



说明函数的梯度方向是在一点等值线(面)的法线方向

2) 当方向 S 与梯度的夹角为零时

$$\frac{\partial f(X^k)}{\partial S} = [\nabla f(X^k)]^T \cdot S = \|\nabla f(X^k)\|$$



说明方向导数达到最大值，故梯度方向是函数在一点上方向导数最大的方向。


与梯度的相反的方向称为负梯度方向，记作 $-\nabla f(X^k)$ ，

它是函数在一点上函数值下降最快的方向。

3) 当方向 S 与梯度方向的夹角为锐角时

$$\frac{\partial f(X^k)}{\partial S} = [\nabla f(X^k)]^T \cdot S > 0$$


说明与梯度成锐角的方向是函数值上升的方向。



4) 当方向 S 与梯度方向的夹角为钝角时

$$\frac{\partial f(X^k)}{\partial S} = [\nabla f(X^k)]^T \cdot S < 0$$

说明与梯度成钝角的方向是函数值下降的方向



可见函数的梯度具有以下性质：

- (1) 梯度是一个向量。
- (2) 梯度方向是等值线(面)的外法线方向。
- (3) 梯度是函数在一点邻域内局部性态的描述。

2.3 多元函数的泰勒展开

一元函数 $f(x)$ 若在点的邻域内 n 阶可导，则函数可在该点的邻域内可作如下展开：

$$f(x) = f(x_k) + f'(x_k) \cdot (x - x_k) + f''(x_k) \cdot (x - x_k)^2 + \cdots + R_n$$

多元函数 $f(X)$ 在某点 X^k 也可泰勒展开，展开式一般取三项

$$\begin{aligned} f(X) \approx & f(X^k) + [\nabla f(X^k)]^T [X - X^k] \\ & + \frac{1}{2} [X - X^k]^T \nabla^2 f(X^k) [X - X^k] \end{aligned}$$

其中 $\nabla^2 f(X^k)$ 称二阶导数矩阵。

二阶导数矩阵的组成

$$\nabla^2 f(\mathbf{X}^k) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_1^2} & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_1 \partial \mathbf{x}_2} & \cdots & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_1 \partial \mathbf{x}_n} \\ \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_2 \partial \mathbf{x}_1} & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_2^2} & \cdots & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_2 \partial \mathbf{x}_n} \\ \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_n \partial \mathbf{x}_1} & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_n \partial \mathbf{x}_2} & \cdots & \frac{\partial^2 f(\mathbf{X}^k)}{\partial \mathbf{x}_n^2} \end{bmatrix}$$

可以看出，函数的二阶导数矩阵是一个 $n \times n$ 阶对称矩阵。

矩阵的正定性

矩阵有正定、负定和不定之分：

对于任意非零向量 \mathbf{X}

(1) 若有

$$\mathbf{X}^T \mathbf{H} \mathbf{X} > 0$$

则称矩阵 \mathbf{H} 是正定矩阵；

(2) 若有

$$\mathbf{X}^T \mathbf{H} \mathbf{X} < 0$$

则称矩阵 \mathbf{H} 是负定矩阵；

(3) 若有时 $\mathbf{X}^T \mathbf{H} \mathbf{X} > 0$ 有时 $\mathbf{X}^T \mathbf{H} \mathbf{X} < 0$

则称矩阵 \mathbf{H} 是不定矩阵。

矩阵正定性的判定（主子式法）

(1) 如果矩阵***H***的各阶主子式的值均大于零，即

一阶主子式 $|h_{11}| > 0$

二阶主子式 $\begin{vmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{vmatrix} > 0$

三阶主子式

$$\begin{vmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{vmatrix} > 0$$

...

则矩阵***H***是正定的；

(2) 如果矩阵***H***的各阶主子式的值负正相间，即

奇数阶主子式小于零，偶数阶主子式大于零时，

矩阵***H***负定；

(3) 其他情况下***H***不定。

例2-2 用泰勒展开的方法将函数 $f(\mathbf{X}) = x_1^5 + x_2^4$ 在点 $\mathbf{X}^1 = [1, 1]^T$ 简化成线性函数和二次函数。

解：分别求函数在点 \mathbf{X}_1 的函数值、梯度和二阶导数矩阵为

$$f(\mathbf{X}^1) = 2$$

$$\nabla f(\mathbf{X}^1) = \begin{bmatrix} 5x_1^4 \\ 4x_2^3 \end{bmatrix}_{\begin{bmatrix} 1 \\ 1 \end{bmatrix}} = \begin{bmatrix} 5 \\ 4 \end{bmatrix}$$

$$\nabla^2 f(\mathbf{X}^1) = \begin{bmatrix} 20x_1^3 & 0 \\ 0 & 12x_2^2 \end{bmatrix}_{\begin{bmatrix} 1 \\ 1 \end{bmatrix}} = \begin{bmatrix} 20 & 0 \\ 0 & 12 \end{bmatrix}$$

$$\mathbf{X} - \mathbf{X}^1 = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix}$$

代入泰勒展开式得简化的线性函数

$$\begin{aligned}f(X) &\approx f(X^1) + [\nabla f(X^1)]^T [X - X^1] \\&= 2 + [5 \ 4] \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix} \\&= 5x_1 + 4x_2 - 7\end{aligned}$$

和展开式的二次项

$$\begin{aligned}&\frac{1}{2} [X - X^1]^T \nabla^2 f(X^1) [X - X^1] \\&= \frac{1}{2} [x_1 - 1, x_2 - 1] \begin{bmatrix} 20 & 0 \\ 0 & 12 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix} \\&= 10(x_1 - 1)^2 + 6(x_2 - 1)^2\end{aligned}$$

将上面的结果相加得简化后的二次函数

$$\begin{aligned}f(X) &\approx 10(x_1 - 1)^2 + 6(x_2 - 1)^2 + 5x_1 + 4x_2 - 7 \\&= 10x_1^2 + 6x_2^2 - 15x_1 - 8x_2 + 9\end{aligned}$$

2.4 正定二次函数



二次函数可以写成以下向量形式：

$$f(X) = \frac{1}{2} X^T H X + B^T X + c$$

如果 H 是正定的，则函数 $f(X)$ 称正定二次函数。

正定二次函数具有以下性质：

- (1) 正定二次函数的等值线（面）是一族同心椭圆（球），其中心就是该二次函数的极小点。
- (2) 非正定二次函数在极小点附近的等值线（面）近似于椭圆（球）。



2.5 多元函数的极值条件

2.5.1 无约束问题的极值条件

一元函数 $f(x)$ 在点 x_k 取得极值的

必要条件

$$f'(x_k) = 0$$

充分条件

$$f''(x_k) \neq 0$$

当 $f''(x_k) > 0$ 时, 取极小值。

当 $f''(x_k) < 0$ 时, 取极大值。

多元函数 $f(X)$ 在点 X^k 取得极值的

必要条件 $\nabla f(X^k) = 0$

把函数在点 \mathbf{X}^k 展开成泰勒二次式，将必要条件代入，有

$$f(\mathbf{X}) - f(\mathbf{X}^k) = \frac{1}{2} [\mathbf{X} - \mathbf{X}^k]^T \nabla^2 f(\mathbf{X}^k) [\mathbf{X} - \mathbf{X}^k]$$

当 \mathbf{X}^k 为函数的极小点时，有

$$[\mathbf{X} - \mathbf{X}^k]^T \nabla^2 f(\mathbf{X}^k) [\mathbf{X} - \mathbf{X}^k] > 0$$

这说明 $\nabla^2 f(\mathbf{X}^k)$ 是正定的

同理，当 \mathbf{X}^k 为函数的极大点时，有

$$[\mathbf{X} - \mathbf{X}^k]^T \nabla^2 f(\mathbf{X}^k) [\mathbf{X} - \mathbf{X}^k] < 0$$

这说明 $\nabla^2 f(\mathbf{X}^k)$ 是负定的

可见，多元函数极值的充分条件是：

当 $\nabla^2 f(X^k)$ 正定时 \rightarrow 在 X^k 取极小值

当 $\nabla^2 f(X^k)$ 负定时 \rightarrow 在 X^k 取极大值

当 $\nabla^2 f(X^k)$ 不定时 \rightarrow 在 X^k 无极值

例2-3 求函数 $f(X) = x_1^3 + x_2^3 + 3x_1^2 + 2x_2^2 - 9x_1 - 4x_2$ 的极值。

解：由极值的必要条件

$$\nabla f(X) = \begin{bmatrix} 3x_1^2 + 6x_1 - 9 \\ 3x_2^2 + 4x_2 - 4 \end{bmatrix} = 0$$

解得以下四个驻点：

$$\begin{aligned} X^1 &= \begin{bmatrix} 1 \\ 2/3 \end{bmatrix}, & X^2 &= \begin{bmatrix} 1 \\ -2 \end{bmatrix} \\ X^3 &= \begin{bmatrix} -3 \\ 2/3 \end{bmatrix}, & X^4 &= \begin{bmatrix} -3 \\ -2 \end{bmatrix} \end{aligned}$$

由极值的充分条件得

$$\nabla^2 f(X^1) = \begin{bmatrix} 6x_1 + 6 & 0 \\ 0 & 6x_2 + 4 \end{bmatrix} \begin{bmatrix} 1 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 12 & 0 \\ 0 & 8 \end{bmatrix} \quad \text{矩阵正定}$$

$$\nabla^2 f(X^2) = \begin{bmatrix} 6x_1 + 6 & 0 \\ 0 & 6x_2 + 4 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 12 & 0 \\ 0 & -8 \end{bmatrix} \quad \text{矩阵不定}$$

$$\nabla^2 f(X^3) = \begin{bmatrix} 6x_1 + 6 & 0 \\ 0 & 6x_2 + 4 \end{bmatrix} \begin{bmatrix} -3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} -12 & 0 \\ 0 & 8 \end{bmatrix} \quad \text{矩阵不定}$$

$$\nabla^2 f(X^4) = \begin{bmatrix} 6x_1 + 6 & 0 \\ 0 & 6x_2 + 4 \end{bmatrix} \begin{bmatrix} -3 \\ -2 \end{bmatrix} = \begin{bmatrix} -12 & 0 \\ 0 & -8 \end{bmatrix} \quad \text{矩阵负定}$$

由此知

X^1 是函数的极小值点, X^4 是函数的极大值点,

X^2 和 X^3 均为非极值点。

2.5.2 约束问题的极值条件

(1) 等式约束问题的极值条件

由高等数学可知，对于等式约束优化问题

$$\begin{array}{ll} \min & f(X) \\ \text{s.t.} & h_v(X) = 0 \quad (v = 1, 2, \dots, m) \end{array}$$

可以建立如下拉格朗日函数极小化问题

$$\min L(X, \lambda) = f(X) + \sum_{v=1}^m \lambda_v h_v(X)$$

两问题同解

令 $\nabla L(X^*, \lambda) = 0$ ，得

$$\nabla f(X^*) + \sum_{v=1}^m \lambda_v \nabla h_v(X^*) = 0$$

λ_v 不全为零

这就是等式约束问题极值的必要条件。简称k-t条件。

k-t条件可以描述为：目标函数的负梯度等于起作用约束函数梯度的非零线性组合。

(2) 不等式约束问题的极值条件

对于不等式约束优化问题

$$\begin{array}{ll}\min & f(X) \\ \text{s.t.} & g_u(X) \leq 0 \quad (u=1,2,\dots,p)\end{array}$$

引入 m 个松弛变量 $x_{n+u} \geq 0$ ，将不等式约束变成等式约束

$$\begin{array}{ll}\min & f(X) \\ \text{s.t.} & g_u(X) + x_{n+u}^2 = 0 \quad (u=1,2,\dots,p)\end{array}$$

建立拉格朗日函数

$$L(X, \lambda, \bar{X}) = f(X) + \sum_{u=1}^p \lambda_u [g_u(X) + x_{n+u}^2]$$

令 $\nabla L(X, \lambda, \bar{X}) = 0$, 有

$$\begin{aligned}\nabla f(X^*) + \sum_{i \in I_k} \lambda_i \nabla g_i(X^*) &= 0 \\ \lambda_i &\geq 0 \quad (i \in I_k)\end{aligned}$$

这就是不等式约束问题的极值条件, 称 **k-t条件**。

其中, I_k 代表点 X^k 的起作用约束的下标集合, 即

$$I_k = \{u \mid g_u(X) = 0, \quad u = 1, 2, \dots, p\}$$

起作用约束: 即 **敏感性约束**。

若有 $g_u(X^k) = 0$, 则称 $g_u(X) \leq 0$ 为点 X^k 的起作用约束。


或者说, 若某约束边界通过点 X^k , 则称对应的约束为该点的起作用约束。

k-t条件的意义:

目标函数的负梯度等于起作用约束梯度的非负线性组合

k-t条件的几何意义:

目标函数的负梯度位于起作用约束梯度所成夹角或锥体之内。



例2-3 用 $k-t$ 条件判断：点 $\mathbf{X}^k = [2, 0]^T$ 是否为下面问题的极小点。

$$\begin{aligned} \min f(\mathbf{X}) &= (x_1 - 3)^2 + x_2^2 \\ s.t. \quad g_1(\mathbf{X}) &= x_1^2 + x_2 - 4 \leq 0 \\ g_2(\mathbf{X}) &= -x_2 \leq 0 \\ g_3(\mathbf{X}) &= -x_1 \leq 0 \end{aligned}$$

解：因 $g_1(\mathbf{X}^k) = 2^2 + 0 - 4 = 0$

$$g_2(\mathbf{X}^k) = 0$$

$$g_3(\mathbf{X}^k) = -2$$

点 \mathbf{X}^k 的起作用约束是

$$g_1(\mathbf{X}) \leq 0$$

和

$$g_2(\mathbf{X}) \leq 0$$

在点 \mathbf{X}^k $\nabla f(\mathbf{X}^k) = \begin{bmatrix} 2(x_1 - 3) \\ 2x_2 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \end{bmatrix}$

$$\nabla g_1(\mathbf{X}^k) = \begin{bmatrix} 2x_1 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

$$\nabla g_2(\mathbf{X}^k) = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

将以上梯度值代入 **k-t** 条件

$$-\nabla f(X^k) = \lambda_1 \nabla g_1(X^k) + \lambda_2 \nabla g_2(X^k)$$

$$-\begin{bmatrix} -2 \\ 0 \end{bmatrix} = \lambda_1 \begin{bmatrix} 4 \\ 1 \end{bmatrix} + \lambda_2 \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

解得 $\lambda_1 = \lambda_2 = 0.5$,

均大于零, 满足 **k-t** 条件。

说明

$$X^k = [2, 0]^T$$

就是所求**最优点**, 如图所示。

