

# 第4章 无约束优化方法

---

求解无约束优化问题

$$\min \mathbf{f}(\mathbf{X})$$

的数值迭代解法，称为无约束优化方法。

方法的基本问题是：选择搜索方向

不同的搜索方向，构成不同的无约束优化算法。

方法分：导数法和模式法两类

导数法：利用梯度和二阶导数构造搜索方向  
如梯度法、牛顿法、  
变尺度法、共扼梯度法等

模式法：利用某些点上的函数值构造搜索方向  
如坐标轮换法、鲍威尔法等

---

## 4.1 梯度法

梯度法是一种古老的优化算法，它的迭代方向是由负梯度构成的，也称最速下降法。

梯度法的迭代算式是

$$\begin{aligned} S^k &= -\nabla f(X^k) \\ X^{k+1} &= X^k + a_k S^k \end{aligned}$$

或

$$X^{k+1} = X^k - a_k \nabla f(X^k)$$

式中， $\alpha_k$  为最优步长因子，由一维搜索确定，即

$$\min f(X^k - \alpha \nabla f(X^k)) \rightarrow \alpha_k$$


根据极值的必要条件和复合函数的求导公式，有

$$\nabla f(X^{k+1}) = -\left[\nabla f(X^k - \alpha_k \nabla f(X^k))\right]^T \nabla f(X^k) = 0$$

$$[\nabla f(X^{k+1})]^T \nabla f(X^k) = 0$$

此式表明：

相邻两迭代点的梯度是彼此正交的，  
相邻的搜索方向相互垂直，如图所示。



由图可以看出：

① 向极小点的逼近路径是一条曲折的锯齿形路线，而且越接近极小点，前进速度越慢。

② 离极小点较远时，一次迭代得到的函数下降量较大。

因此，许多收敛性较好的算法，第一步迭代都采用梯度法。

## 梯度法的迭代步骤如下：

(1) 给定初始点 $\mathbf{X}^0$ 和收敛精度 $\varepsilon$ ，置 $\mathbf{k}=0$ ；

(2) 计算梯度，并构造搜索方向

$$\mathbf{S}^k = -\nabla f(\mathbf{X}^k)$$

(3) 一维搜索，求新的迭代点

$$\min f(\mathbf{X}^k - \alpha \nabla f(\mathbf{X}^k)) \rightarrow \alpha_k$$
$$\mathbf{X}^{k+1} = \mathbf{X}^k - \alpha_k \nabla f(\mathbf{X}^k)$$

(4) 收敛判断：若满足

$$\|\nabla f(\mathbf{X}^{k+1})\| \leq \varepsilon$$

则令  $\mathbf{X}^* = \mathbf{X}^{k+1}$ ， $\mathbf{f}(\mathbf{X}^*) = \mathbf{f}(\mathbf{X}^{k+1})$  终止计算；

否则，令 $\mathbf{k}=\mathbf{k}+1$ ，转（2）继续迭代。

### 例4-1 用梯度法求解无约束最优化问题

$$\min f(X) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1$$

$$\text{已知 } X^0 = [1, 1]^T, \quad \varepsilon = 0.1$$

解 (1) 第一次迭代

$$\text{求 } \nabla f(X) = \begin{bmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{bmatrix}, \quad \nabla f(X^0) = \begin{bmatrix} -4 \\ 2 \end{bmatrix}$$

$$\text{令 } S^0 = -\nabla f(X^0) = \begin{bmatrix} 4 \\ -2 \end{bmatrix}$$

$$\text{则有 } X^1 = X^0 + \alpha_0 S^0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \alpha_0 \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 1 + 4\alpha_0 \\ 1 - 2\alpha_0 \end{bmatrix}$$

$$f(X^1) = (1 + 4\alpha_0)^2 + 2(1 - 2\alpha_0)^2 - 2(1 + 4\alpha_0)(1 - 2\alpha_0) - 4(1 + 4\alpha_0) = f(\alpha_0)$$

$$\text{令 } f'(\alpha_0) = 8(1 + 4\alpha_0) - 8(1 - 2\alpha_0) - 8(1 - 2\alpha_0) + 4(1 + 4\alpha_0) - 16 = 0$$

解得

$$\alpha_0 = \frac{1}{4} = 0.25, \quad X^1 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix}, \quad f(X^1) = -5.5$$

因  $\|\nabla f(X^1)\| = \sqrt{5} > \varepsilon$  还需继续迭代

## (2) 第二次迭代

同理有

$$\nabla f(X^1) = \begin{bmatrix} -1 \\ -2 \end{bmatrix}, \quad S^1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$X^2 = X^1 + \alpha_1 S^1 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix} + \alpha_1 \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 + \alpha_1 \\ 0.5 + 2\alpha_1 \end{bmatrix}$$

$$f(X^2) = (2 + \alpha_1)^2 + 2(0.5 + 2\alpha_1)^2 - 2(2 + \alpha_1)(0.5 + 2\alpha_1) - 4(2 + \alpha_1) = f(\alpha_1)$$

$$f'(\alpha_1) = 2(2 + \alpha_1) + 8(0.5 + 2\alpha_1) - 2(0.5 + 2\alpha_1) - 4(2 + \alpha_1) - 4 = 0$$

解得  $\alpha_1 = 0.5$

$$X^2 = \begin{bmatrix} 2.5 \\ 1.5 \end{bmatrix}, \quad f(X^2) = -6.75$$


$$\nabla f(X^2) = \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

因  $\|\nabla f(X^2)\| = \sqrt{5} > \varepsilon$

可知  $X^2$  也不是极小点，  
还应继续进行迭代。

此问题的最优解是

$$X^* = [4, 2]^T, \quad f(X^*) = -8$$



用梯度法求解时，需要经过相当多次迭代才能得到一个近似的最优解。其中前两次的迭代路线如图所示。



## 4.2 牛顿法

牛顿法的搜索方向由目标函数的负梯度和二阶导数矩阵构造。

### 4.2.1 基本牛顿法

将函数  $f(\mathbf{X})$  在点  $\mathbf{X}^k$  处展成泰勒二次式：

$$f(\mathbf{X}) \approx f(\mathbf{X}^{(k)}) + [\nabla f(\mathbf{X}^{(k)})]^T [\mathbf{X} - \mathbf{X}^k] + \frac{1}{2} [\mathbf{X} - \mathbf{X}^k]^T \nabla^2 f(\mathbf{X}^k) [\mathbf{X} - \mathbf{X}^k]$$

对上式求梯度，并设  $\mathbf{X}^{(k+1)}$  是函数的极小点，则有

$$\nabla f(\mathbf{X}^{k+1}) = \nabla f(\mathbf{X}^k) + \nabla^2 f(\mathbf{X}^k) [\mathbf{X}^{k+1} - \mathbf{X}^k] = 0$$

由此解得 
$$\mathbf{X}^{k+1} = \mathbf{X}^k - [\nabla^2 f(\mathbf{X}^k)]^{-1} \nabla f(\mathbf{X}^k)$$

令 
$$\mathbf{S}^k = -[\nabla^2 f(\mathbf{X}^k)]^{-1} \nabla f(\mathbf{X}^k) \quad \text{则有} \quad \mathbf{X}^{k+1} = \mathbf{X}^k + \mathbf{S}^k$$

由此构成的算法称基本牛顿法， $\mathbf{S}^k$  称牛顿方向。


分析可知：

(1) 对于正定二次函数， $\mathbf{X}^{k+1}$ 是精确极小点，方向  $\mathbf{S}^k$  是直指函数的极小点。

(2) 用基本牛顿法求解正定二次函数时，无论从哪个初始点出发，计算所得牛顿方向直指极小点，而且步长等于1。

(3) 对于一般非线性函数，点 $\mathbf{X}^{k+1}$ 只是原函数的一个近似极小点。故将此点作为下一个迭代 $\mathbf{X}^{k+1}$ 。

(4) 但是对于非正定函数，由上式得到的点 $\mathbf{X}^{k+1}$ ，不能始终保持函数的下降性，基本牛顿法有可能失败。如图所示，



原因：步长因子总是等于1，

改进方法：引入步长因子和一维搜索。

由此构成如下阻尼牛顿法。

#### 4.2.2 阻尼牛顿法

$$\begin{aligned} \text{令} \quad & S^k = -[\nabla^2 f(X^k)]^{-1} \nabla f(X^k) \\ & \min_{\alpha} f(X^k + \alpha S^k) \rightarrow \alpha_k \\ & X^{k+1} = X^k + \alpha_k S^k \end{aligned}$$

由此建立的算法就是阻尼牛顿法， $\alpha_k$  称阻尼因子

## 牛顿法的特点:

- (1) 构造搜索方向利用了函数的所有的一阶导数和二阶导数，产生的搜索方向直指极小点；
- (2) 对于正定二次函数，从任意初始点出发，一次迭代即可得到极小点。对于一般函数，迭代的次数比其它算法都要少。
- (3) 每次迭代都需要计算函数的二阶导数矩阵及其逆矩阵。计算量大，计算时间长，计算速度较慢。
- (4) 计算中，用差分代替微分。所得梯度和二阶导数矩阵，以及求得的牛顿方向都存在较大误差。

### 例4-2 用牛顿法求解例4-1

$$\min f(X) = x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1$$

已知  $X^0 = [1, 1]^T, \quad \varepsilon = 0.1$

解 1) 用基本牛顿法

计算  $\nabla f(X) = \begin{bmatrix} 2x_1 - 2x_2 - 4 \\ -2x_1 + 4x_2 \end{bmatrix}$

$$\nabla^2 f(X) = \begin{bmatrix} 2 & -2 \\ -2 & 4 \end{bmatrix}, \quad \nabla f(X^0) = \begin{bmatrix} -4 \\ 2 \end{bmatrix}$$

$$[\nabla^2 f(X)]^{-1} = \begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/2 \end{bmatrix}$$

$$S^0 = -[\nabla^2 f(X^0)]^{-1} \nabla f(X^0) = -\begin{bmatrix} 1 & 1/2 \\ 1/2 & 1/2 \end{bmatrix} \begin{bmatrix} -4 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$$

$$X^1 = X^0 + S^0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}, \quad f(X^1) = -8$$

因  $\nabla f(X^1) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \|\nabla f(X^1)\| = 0$

故最优解是:  $X^* = X^1 = \begin{bmatrix} 4 \\ 2 \end{bmatrix}, \quad f(X^*) = -8$

## 2) 用阻尼牛顿法

$$X^1 = X^0 + \alpha_0 S^0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \alpha_0 \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 + 3\alpha_0 \\ 1 + \alpha_0 \end{bmatrix}$$

代入原函数

$$f(X^1) = (1 + 3\alpha_0)^2 + 2(1 + \alpha_0)^2 - 2(1 + 3\alpha_0)(1 + \alpha_0) - 4(1 + 3\alpha_0) = f(\alpha_0)$$

对  $\alpha$  求导

$$f'(\alpha_0) = 6(1 + 3\alpha_0) + 4(1 + \alpha_0) - 6(1 + \alpha_0) - 2(1 + 3\alpha_0) - 12 = 0$$

解得  $\alpha_0 = 1$

$$X^1 = X^0 + \alpha_0 S^0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$$

因  $f(X^1) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ,  $\|\nabla f(X^1)\| = 0$

最优解为  $X^* = X^1 = \begin{bmatrix} 4 \\ 2 \end{bmatrix}$ ,  $f(X^*) = -8$

可以看出：

此解与基本牛顿法的计算结果完全相同。

两种方法都只进行了一次迭代，这是因为标函数是正定二次函数，基本牛顿法的局限性还没有显露出来的缘故。

基本牛顿法不需一维搜索，因此计算速度较快。

### 4.2.3 变尺度法

基本思想:

(1) 用简单矩阵代替二阶导数矩阵的逆矩阵

$$[\nabla^2 f(X^k)]^{-1}$$

(2) 用坐标变换简化目标函数

引入矩阵变换 $\mathbf{U}$ , 令  $\mathbf{X} - \mathbf{X}^k = \mathbf{U}\mathbf{Y}$

代入式泰勒展开式得

$$\phi(\mathbf{Y}) = \frac{1}{2} \mathbf{Y}^T \mathbf{U}^T \nabla^2 f(\mathbf{X}^k) \mathbf{U} \mathbf{Y} + [\nabla f(\mathbf{X}^k)]^T \mathbf{U} \mathbf{Y} + f(\mathbf{X}^k)$$

若  $\nabla^2 f(\mathbf{X}^k)$  正定, 必存在矩阵 $\mathbf{U}$

使  $\mathbf{U}^T \nabla^2 f(\mathbf{X}^k) \mathbf{U} = \mathbf{I}$  (4-12)



代入前式得

$$\phi(Y) = \frac{1}{2} Y^T Y + \nabla^2 f(X^k)^T U Y + f(X^k)$$

上式中只包含 $Y$ 的二次项和一次项，采用坐标平移可消去一次项，使其等值线变为同心椭圆（球）。

用  $U$  和  $U^{-1}$  分别左乘和右乘式(4-12)，有

$$UU^T \nabla^2 f(X^k) = I$$

$$[\nabla^2 f(X^k)]^{-1} = UU^T$$

$$U^T \nabla^2 f(X^k) U = I$$

由此可见，通过坐标变换可以得到  $[\nabla^2 f(X^k)]^{-1}$

---

将上式代入牛顿法的迭代算式得

$$\begin{aligned}S^k &= -UU^T \nabla f(X^k) \\ X^{k+1} &= X^k - \alpha_k UU^T \nabla f(X^k)\end{aligned}$$

记矩阵  $A = -UU^T$ ，称变尺度矩阵，则有

$$\begin{aligned}S^k &= -A^k \nabla f(X^k) \\ X^{k+1} &= X^k - \alpha_k A^k \nabla f(X^k)\end{aligned}$$

由以上两式构成的下降迭代解法称变尺度法。

其中

$$S^k = -A^k \nabla f(X^k)$$

称变尺度方向。

---

经推导，变尺度矩阵可由以下递推公式得到：

$$A^{k+1} = A^k + E^k$$

其中， $A^0=I$ （单位矩阵）； $E^k$ 称校正矩阵

$$E^k = \frac{\Delta X^k [\Delta X^k]^T}{[\Delta g^k]^T \Delta X^k} - \frac{A^k \Delta g^k [\Delta g^k]^T A^k}{[\Delta g^k]^T A^k \Delta g^k}$$

式中

$$\begin{aligned}\Delta X^k &= X^{k+1} - X^k \\ \Delta g^k &= \nabla f(X^{k+1}) - \nabla f(X^k)\end{aligned}$$

## 4.2.4 共轭梯度法

### 4.2.4.1 共轭方向

设 $\mathbf{H}$ 为正定对称矩阵，有一组非零向量  $\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_n$  满足

$$\mathbf{s}_i^T \mathbf{H} \mathbf{s}_j = 0 \quad (i \neq j)$$

则称这组向量关于矩阵 $\mathbf{H}$ 共轭，或是 $\mathbf{H}$ 的一组共轭向量。

当 $\mathbf{H}$ 为单位矩阵时，即有

$$\mathbf{s}_i^T \mathbf{s}_j = 0 \quad (i \neq j)$$


此时称向量  $\mathbf{s}_n$  ( $i=1, 2, \dots, n$ ) 相互正交。

共轭方向具有以下性质：

- (1) 对于正定二次函数，从任意初始点 $\mathbf{X}^0$ 出发，依次沿一组（ $n$ 个）共轭方向一维搜索，最多 $n$ 次即可以达到极小点。
- (2) 从任意两点 $\mathbf{X}_1^0$ 和 $\mathbf{X}_2^0$ 出发，分别沿同一方向 $\mathbf{S}^0$ 进行一维搜索，得到两个一维极小点 $\mathbf{X}_1^1$ 和 $\mathbf{X}_2^1$ ，则连接此两点所形成的向量

$$\mathbf{S}^1 = \mathbf{X}_1^1 - \mathbf{X}_2^1$$

与原方向 $\mathbf{S}^0$ 关于该函数的二阶导数矩阵相共轭。



#### 4.2.4.2 共轭方向的产生

平行搜索法 向量组合法。

##### 1. 平行搜索法

见后面的鲍威尔法

##### 2. 向量组合法

###### (1) 基向量组合法

取 $n$ 个基向量 $\mathbf{e}^i$  ( $i=0, 1, \dots, n-1$ ) 和另一个独立向量 $\mathbf{S}^0$ ,

令

$$\mathbf{S}^1 = \mathbf{e}^0 + \beta_0 \mathbf{S}^0 \quad (4-26)$$

式中,  $\beta_0$ 为待定常数。称 $\mathbf{S}^0$ 是 $\mathbf{e}^0$ 和 $\mathbf{S}^1$ 的线性组合。

欲使  $\mathbf{S}^0$  和  $\mathbf{S}^1$  关于函数的二阶导数矩阵相共轭，则必须使

$$[\mathbf{S}^0]^T \nabla^2 f(\mathbf{X}^k) \mathbf{S}^1 = 0 \quad (4-27)$$

将式（4-26）代入上式解得

解得

$$\beta_0 = -\frac{[\mathbf{S}^0]^T \nabla^2 f(\mathbf{X}^k) \mathbf{e}^0}{[\mathbf{S}^0]^T \nabla^2 f(\mathbf{X}^k) \mathbf{S}^0}$$

代入式（4-26）得到与  $\mathbf{S}^0$  共轭的向量

$$\mathbf{S}^1 = \mathbf{e}^0 - \frac{[\mathbf{S}^0]^T \nabla^2 f(\mathbf{X}^k) \mathbf{e}^0}{[\mathbf{S}^0]^T \nabla^2 f(\mathbf{X}^k) \mathbf{S}^0} \cdot \mathbf{S}^0$$

同理，若已求得 **k+1** 个共轭向量  $\mathbf{S}^0, \mathbf{S}^1, \dots, \mathbf{S}^k$ ，  
令新的向量

$$\mathbf{S}^{k+1} = \mathbf{e}^k + \sum_{i=0}^k \beta_i \mathbf{S}^i$$

解得

$$\beta_i = - \frac{[\mathbf{S}^i]^T \nabla^2 f(\mathbf{X}^k) \mathbf{e}^i}{[\mathbf{S}^i]^T \nabla^2 f(\mathbf{X}^k) \mathbf{S}^i}$$

于是，有

$$\mathbf{S}^{k+1} = \mathbf{e}^k - \sum_{i=0}^k \frac{[\mathbf{S}^i]^T \nabla^2 f(\mathbf{X}^k) \mathbf{e}^i}{[\mathbf{S}^i]^T \nabla^2 f(\mathbf{X}^k) \mathbf{S}^i} \mathbf{S}^i$$

此向量就是与原 **k+1** 个向量相共轭的新向量。



### 4.2.5 梯度组合法

将函数 $f(\mathbf{X})$ 展开为如下二次函数

$$f(\mathbf{X}) = \frac{1}{2} \mathbf{X}^T \mathbf{H} \mathbf{X} + \mathbf{B}^T \mathbf{X} + c$$

从任意点  $\mathbf{X}^k$  出发，沿函数的负梯度方向作一次一维搜索

令  $\mathbf{S}^k = -\nabla f(\mathbf{X}^k)$  (4-34)

得  $\mathbf{X}^{k+1} = \mathbf{X}^k + \alpha_k \mathbf{S}^k$  (4-35)

又令  $\mathbf{S}^{k+1} = -\nabla f(\mathbf{X}^{k+1}) + \beta_k \mathbf{S}^k$  (4-36)

把式 (4-34) 和式 (4-36) 代入共轭条件

$$[\mathbf{S}^{k+1}]^T \mathbf{H} \mathbf{S}^k = 0 \quad (4-37)$$

$$-[\nabla f(\mathbf{X}^k)]^T \mathbf{H} [-\nabla f(\mathbf{X}^{k+1}) + \beta_k \mathbf{S}^k] = 0$$

由此解得

$$\beta_k = \frac{[\nabla f(X^k)]^T H \nabla f(X^{k+1})}{[\nabla f(X^k)]^T H \nabla f(X^k)}$$

由于

$$\nabla f(X^k) = HX^k + B$$

$$\nabla f(X^{k+1}) = HX^{k+1} + B$$

两式相减并将式（**4-35**）代入得

$$a_k HS^k = \nabla f(X^{k+1}) - \nabla f(X^k)$$

将式（**4-36**）和上式的两边分别相乘，并注意式（**4-37**）得

$$[-\nabla f(X^{k+1}) + \beta_k \nabla f(X^k)]^T [\nabla f(X^{k+1}) - \nabla f(X^k)] = 0$$

将上式展开，并注意到相邻两点梯度间的正交关系，整理后得

$$\beta_k = \frac{[\nabla f(X^{k+1})]^T \nabla f(X^{k+1})}{[\nabla f(X^k)]^T \nabla f(X^k)} = \frac{\|\nabla f(X^{k+1})\|^2}{\|\nabla f(X^k)\|^2}$$

### 4.3 共轭梯度法

把上式代入式（4-36）得

$$S^{k+1} = -\nabla f(X^{k+1}) + \frac{\|\nabla f(X^{k+1})\|^2}{\|\nabla f(X^k)\|^2} S^k$$
$$X^{k+2} = X^{k+1} + \alpha_{k+1} S^{k+1}$$

可见，只需利用相邻两点的梯度就可以构造一个共轭方向。

以这种方式产生共轭方向并进行迭代运算的算法称共轭梯度法。

#### 例4-4 用共轭梯度法求解例4-1。

解（1）第一次迭代沿负梯度方向搜索。由例4-1得

$$X^0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \nabla f(X^0) = \begin{bmatrix} -4 \\ 2 \end{bmatrix}, S^0 = \begin{bmatrix} 4 \\ -2 \end{bmatrix}$$

$$X^1 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix}, \nabla f(X^1) = \begin{bmatrix} -1 \\ -2 \end{bmatrix}$$

（2）第二次迭代。求

$$\beta_0 = \frac{\|\nabla f(X^1)\|^2}{\|\nabla f(X^0)\|^2} = \frac{5}{20} = 0.25$$

$$S^1 = -\nabla f(X^1) + \beta_0 S^0 = -\begin{bmatrix} -1 \\ -2 \end{bmatrix} + 0.25 \begin{bmatrix} 4 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1.5 \end{bmatrix}$$

$$X^2 = X^1 + \alpha_1 S^1 = \begin{bmatrix} 2 \\ 0.5 \end{bmatrix} + \alpha_1 \begin{bmatrix} 2 \\ 1.5 \end{bmatrix} = \begin{bmatrix} 2 + 2\alpha_1 \\ 0.5 + 1.5\alpha_1 \end{bmatrix}$$

---

$$f(X^2) = (2 + 2\alpha_1)^2 + 2(0.5 + 1.5\alpha_1)^2 - 2(2 + 2\alpha_1)(0.5 + 1.5\alpha_1) - 4(2 + 2\alpha_1) = f(\alpha_1)$$

$$f'(\alpha_1) = 4(2 + 2\alpha_1) + 6(0.5 + 1.5\alpha_1) - 4(0.5 + 1.5\alpha_1) - 3(2 + 2\alpha_1) - 8 = 0$$

解得  $\alpha_1 = 1$

$$X^2 = \begin{bmatrix} 4 \\ 2 \end{bmatrix}, \quad f(X^2) = -8$$

$$\nabla f(X^2) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

因  $\|\nabla f(X^2)\| = 0$

所以  $X^2 = [4, 2]^T$  和  $f(X^2) = -8$  就是所求最优解。

---

## 4.4 鲍威尔（Powell）法

利用平行搜索构造共轭方向，并沿共轭方向一维搜索的算法。由于方向的产生不需要计算导数，因此属于模式法。

鲍威尔法是模式法中最好的，具有超线性收敛速度。



### 4.4.1 基本思想

从两个初始点出发，沿同一个方向，分别进行两次一维搜索，就可产生一个与原方向共轭的方向。

但算法只能给定一个初始点  $\mathbf{x}^0$ 。

故实现平行搜索的第二个初始点和一个任意方向，只能借助坐标方向在搜索中逐渐产生。

## 4.4.2 迭代过程



### 4.4.3 算法特点

(1) 对于正定二元二次函数，经过两轮迭代，6次一维搜索即可达到极小点。

对正定  $n$  元二次函数，最多经过  $n$  轮迭代， $n(n+1)$  次一维搜索就可达到极小点。

(2) 不需计算函数的导数。

(3) 一维搜索的次数较多，但构成搜索方向的计算极其简单。